

Scikit-learn vs PyCaret

Comparación práctica mediante un prototipo de predicción de éxito académico / riesgo de abandono.

Desarrollo con Tecnologías Emergentes

Grupo 02 · dte2026a3g02

Gonzalo López · Marcos Corrochano · Raúl Rodríguez · Alberto García · Diego López

De TG1/TG2 a TG3: probar, no solo comparar



Misma funcionalidad, dos tecnologías, medición práctica.

Línea: IA para analítica predictiva en educación

Tecnologías: Scikit-learn y PyCaret

Comparación: métricas, tiempos, código, instalación y mantenibilidad

Predict Students' Dropout and Academic Success

Problema y dataset: predicción académica binaria

Dataset UCI

Predict Students' Dropout and Academic Success

4.424 registros originales

37 columnas de información académica, social y administrativa

Variable original: Target



Transformación del problema

Graduate → Exito

Dropout → Riesgo

Enrolled eliminado


Motivo: Enrolled no tiene resultado final cerrado.

3.630

filas usadas tras filtrar

El modelo no “adivina” abandonos reales futuros: clasifica casos de prueba comparando predicción vs. resultado real del dataset.

Diseño experimental: misma prueba para ambos prototipos



Condiciones equivalentes

- Mismo dataset filtrado
- Misma variable objetivo binaria
- Misma partición 80/20
- Misma semilla aleatoria
- Mismas métricas principales

Evidencias generadas

- CSV de métricas
- Tiempos de ejecución
- Matriz de confusión
- Comparación de modelos
- Modelo guardado

La comparación solo es válida porque ambos prototipos resuelven el mismo problema bajo las mismas condiciones.

Prototipo A: Scikit-learn

Qué hace

- Pipeline explícito con StandardScaler
- Comparación de 13 clasificadores con validación cruzada
- Selección de Logistic Regression
- Predicción y métricas sobre test

0,0156s

entrenamiento final

0,0021s

predicción

175

líneas efectivas

3h


desarrollo estimado

Más control y transparencia; más código explícito y más trabajo manual.

Scikit-learn es fuerte cuando se necesita controlar el pipeline y optimizar el modelo final.

Prototipo B: PyCaret

Configura el experimento con `setup()`
Compara modelos con `compare_models()`
Selecciona Logistic Regression
Genera métricas, matriz de confusión y modelo guardado




Resultados clave

Accuracy 0,9421 · F1 Riesgo 0,9255 · Tiempo total 12,78s

PyCaret es fuerte para explorar rápido: automatiza preparación, comparación y selección de modelos.

Resultados comparativos: misma calidad predictiva




Clave

La diferencia no está en la calidad final del modelo: ambos llegan al mismo resultado predictivo.

La comparación se decide por proceso: control, automatización, tiempos, instalación y mantenibilidad.

Diferencias prácticas: rendimiento, código y esfuerzo



PyCaret tarda más porque compara modelos.

Scikit-learn mide el ajuste final del modelo.

No es solo “quién tarda menos”: es qué está midiendo cada tecnología en ese tiempo.



CONCLUSIONES FINALES

No gana una tecnología en todo

La diferencia principal no está en la calidad predictiva, sino en el proceso de desarrollo.


Resultado del experimento

- Misma calidad predictiva
- Mismo modelo final: Logistic Regression
- La comparación se decide por proceso

0,9421 accuracy en ambos


PyCaret destaca por...

- Prototipado rápido
- Menos líneas de código
- Comparación automática de modelos
- Más útil para explorar alternativas



 Mejor para fases iniciales

Scikit-learn destaca por...

- Mayor control del pipeline
- Más transparencia en cada paso
- Mejor rendimiento del modelo final
- Más adecuado para implementación controlada

 Mejor para desarrollos finales

Decisión final: PyCaret acelera la exploración; Scikit-learn aporta control para una implementación más ajustada.



¿PREGUNTAS?

